

논문 2025-62-10-6

딥페이크 이미지 조작 기법과 학습 가능한 컨볼루션 커널을 통한 초고해상화 탐지

(Super-resolution Detection based on Deepfake Image Manipulation
Techniques and Learnable Convolutional Kernels)

최 기 윤*, 윤 성 빈**, 최 중 원***

(Giyun Choi, Sungbin Youn, and Jongwon Choi[©])

요 약

본 논문에서는 GAN 기반 초고해상화(Super-Resolution) 알고리즘과 상용 툴(TOPAZ Labs)을 활용하여 제작된 초고해상화 이미지와 원본 이미지를 구별하기 위한 탐지 모델을 제안한다. 기존 딥페이크 탐지 연구들은 주파수 공간 특성을 활용하거나 사전학습된 백본 모델(Backbone Network)을 통해 성능 개선을 시도했으나, 특정 알고리즘 또는 데이터셋에 국한된 한계를 보였다. 본 연구에서는 학습 가능한 컨볼루션 커널(Learnable Convolution Kernel, LCK)을 통해 초고해상화 이미지의 국소적인 특징을 효과적으로 추출하고, 딥페이크 이미지 조작에 강인하게 사전학습된 ResNet-50 모델을 백본으로 활용하는 탐지 프레임워크를 구축하였다. 이를 통해 다양한 초고해상화 알고리즘 및 상용 툴로 생성된 이미지에 대해 뛰어난 구분 성능을 확보하였으며, 모든 테스트 데이터셋에서 100% 정확도를 달성하였다. 또한, Gradient map 시각화를 통해 제안 모델이 이미지의 엣지 및 텍스처와 같은 세부 정보 활용을 통해 초고해상화 이미지를 효과적으로 식별함을 확인하였다.

Abstract

In this paper, we propose a novel detection model to distinguish between original images and super-resolution (SR) images generated by both GAN-based algorithms (e.g., SRGAN, EDSR, RCAN) and a commercial tool (TOPAZ Labs). Previous deepfake detection studies have attempted to improve performance by leveraging frequency-domain characteristics or pre-trained backbone networks; however, they often suffered from limited adaptability, excelling only on specific algorithms or datasets. To address this, we introduce a framework that extracts fine-grained, local features of super-resolution images via learnable convolution kernels (LCKs) and leverages a ResNet-50 model pre-trained to robustly handle various image manipulations. Our approach demonstrates exceptional detection accuracy across diverse SR datasets, achieving a 100% success rate on all test sets. Furthermore, gradient map visualizations reveal that the proposed model effectively focuses on critical image details, such as edges and textures, to discriminate super-resolution images from their originals.

Keywords : Super-resolution detection, Deepfake detection, Deepfake manipulation, Learnable convolutional kernel, Digital forensic

*비회원, ***정회원, 중앙대학교 영상학과(Department of Advanced Imaging, GSAIM, Chung-Ang University, Seoul, Korea)

**비회원, 대검찰청 과학수사부 법과학분석과(Science Investigation Department, Forensic Science Division, Supreme Prosecution Service)

[©] Corresponding Author(E-mail : choijw@cau.ac.kr)

※ 본 연구는 2024년 대검찰청 연구사업 “디지털 사진파일의 위변조 탐지 기법 연구” 지원으로 수행되었습니다.

Received ; May 7, 2025

Revised ; July 18, 2025

Accepted ; August 17, 2025

I. 서 론

최근 이미지의 해상도를 높이거나, 복원할 수 있는 초고해상화 (Super-Resolution) 알고리즘이 다양한 분야에서 활용되고 있다. 이 기술은 저해상도의 이미지를 고해상도로 변환하여 품질을 극대화하는데 탁월한 성능을 보이며, 의료 영상 분석^[1, 13], 위성 사진 복원^[2], 글자인식^[14] 등을 통해 유용성이 입증되고 있다. 그러나 이러한 기술은 딥페이크 (Deepfake) 생성 기술과 결합될 경우, 저해상도 딥페이크 영상을 고해상도로 변환하여 현실감을 극대화 할 수 있다는 점에서 우려가 제기되고 있다. 더 나아가 허위 정보 확산, 개인 프라이버시 침해, 명예 훼손 등 사회 문제를 야기할 수 있다.

이에 본 연구는 이러한 문제를 해결하기 위해 GAN^[3] 기반 초고해상화 알고리즘 세 가지를 선택하고, 상용 초고해상화 툴 (TOPAZ Labs)을 활용하여 사람 얼굴 초고해상화 이미지 탐지 모델 학습 및 평가를 위한 데이터셋을 구축하였다.

하지만, GAN 기반 초고해상화 데이터셋과 상용 툴으로 제작한 초고해상화 데이터셋간의 차이를 고려하지 않고 학습한 모델은 특정 알고리즘에 대해서만 높은 성능을 보이는 반면, 다른 유형의 이미지에 대해서는 성능이 저하되는 문제를 보였다. 특히, 상용 툴로 생성된 초고해상화 이미지와 원본 이미지를 주파수 공간으로 분석했을 때, GAN 기반 이미지와는 다른 패턴을 보이는 것을 확인하였다. 이는 GAN 기반 초고해상화 알고리즘이 픽셀 단위의 화질 개선에 초점을 맞추고 있어 기존의 딥페이크 탐지 모델과 다른 접근 방식이 필요함을 시사한다. 이를 해결하기 위하여 본 논문에서는 학습 가능한 컨볼루션 커널 (LCK, Learnable Convolutional Kernel)과 “CNNDet”^[4] 방식을 기반을 결합하고 다양한 이미지 조작 환경에서도 강인한 성능을 발휘할 수 있는 초고해상화 이미지 탐지 모델을 제안한다. CNNDet에서는 딥페이크 탐지 알고리즘을 학습 시 데이터셋에 현실적인 물리적 조건 (밝기, 노이즈, 카메라 해상도 등)과 압축 상황을 반영하기 위해 여러 가지 이미지 증강기법을 활용하여 이미지 조작에 강인한 모델로 알려져 있다. 이를 기반으로 다양한 이미지 조작 환경에서도 딥페이크로 제작된 이미지에 초고해상화 알고리즘 사용 유무를 판단하고 높은 성능을 발휘할 수 있는 모델을 개발하였다.

제안된 모델 설계는 학습 가능한 커널이 1차적으로 이미지의 중요한 특징들을 추출하고 이미지 조작에 강

인한 모델에게 넘겨줘 여러 가지 이미지 조작 환경에도 강인하게 학습하게 설계하였다. 이후, 원본 이미지와 초고해상화된 이미지를 구별할 수 있는 탐지 모델을 개발하였다. 초고해상화 탐지 모델은 이미지 입력을 기반으로 원본 해상도의 원본 이미지와 초고해상화 알고리즘을 통해 생성된 가짜 이미지를 이진 분류하는 방식으로 모델링을 진행하였다.

실험 과정에서는 자체 제작 데이터셋 4종을 이용하여 LCK와 이미지 조작에 강인한 ResNet-50^[5] 모델을 학습한 것과, ImageNet^[6]으로 사전학습 된 ResNet-50을 비교하였다. 실험 결과, 논문에서 제안한 모델이 한 번도 보지 못한 (un-seen) 데이터셋에서 우수하게 분류 작업을 수행하는 것을 확인했다.

II. 본 론

1. 초고해상화 이미지 데이터셋 제작

초고해상화 탐지 모델 학습을 위하여 원본 이미지와 초고해상도 이미지를 생성하기 위하여 첫째로는 GAN 기반 초고해상화 모델 SRGAN^[7], EDSR^[8], RCAN^[9] 세 가지를 이용하며, 둘째로는 상용 고해상화 툴 (TOPAZ Labs)의 Upscaling 기능을 통해 각 3천장씩 총 1만 2천장을 수집하였다. 초고해상화 이미지를 제작하기 위하여 기공개된 벤치마크 데이터셋 ‘FaceForensics++’^[10]의 원본 얼굴 데이터만을 사용했다. 4개 알고리즘의 공통된 전처리 방법은 원본 이미지를 특정 비율로 작게 만든 뒤, 이를 원본 이미지의 사이즈로 초고해상화를 적용하여, 동일한 이미지에 대해서 원본과 초고해상화 적용 이미지를 모두 취득할 수 있는자가 학습 방법론 기반의 데이터 취득을 수행하였다. 학습에 사용할 GAN 기반 초고해상화 데이터셋과 TOPAZ 데이터셋, 총 4종의 데이터셋은 각 모델별로 3000장씩 총 12,000장을 확보하였다.




그림 1. GAN, TOPAZ 초고해상화 알고리즘으로 제작한 데이터셋

Fig. 1. Dataset Generated Using GAN and TOPAZ Super-Resolution Algorithms.

2. 초고해상화 이미지 탐지 AI 학습

초고해상화 이미지 탐지 방법은 원본 이미지와 초고해상화 알고리즘을 거친 가짜 이미지를 이진 분류(Binary Classification) 하는 문제로 모델링된다. 일반적으로 대규모 데이터셋으로 학습된 백본 네트워크를 사용하고 특징을 추출한 뒤, 이를 이진 분류 모델에 입력한다. 그림 2번은 초고해상화 탐지 모델의 개요를 보여주며, 원본 이미지 또는 초고해상화 알고리즘으로 생성된 이미지를 입력받아 이진 분류 과정을 수행한다.




그림 2. 초고해상화 탐지 모델 개요도

Fig. 2. Overview of the Super-Resolution Detection Model.

(1) 학습 가능한 컨볼루션 커널 (LCK)

수집된 데이터셋 TOPAZ는 주파수 공간에서 초고해상화를 한 이미지와 원본 이미지 사이의 큰 차이가 존재하지 않는다. 이는 “DCT”^[12]에서 보여준 합성 이미지의 주파수 특징 분석 결과와는 다른 패턴 결과를 보여주고 있다. 이러한 결과는 현재 학습한 모델이 GAN-Based 모델처럼 복원하고 여러 가지 조작(Manipulation)에 강인하게끔 초고해상화 알고리즘이 작동하여 좀 더 세밀한 픽셀 단위 화질을 개선하는 것을 알 수 있다. 이를 해결하기 위하여 본 논문에서는 학습 가능한 컨볼루션 커널 (Learnable Convolution Kerenl)을 제안한다.

초고해상화 이미지는 제안한 커널들을 통과하면서 각 커널의 특성에 따라 특징을 추출하고, 이 과정에서 학습된 파라미터가 업데이트 된다. 그림 3에서는 학습에 사용하는 3가지 커널을 보여준다. ‘filter1’에 해당하는 커널은 라플라시안 (Laplacian) 변형으로 이미지의 엣지를 추출하고 경계를 강조하며 노이즈에 민감한 커널이다. ‘filter2’에 해당하는 커널은 곡률 (Curvature) 커널로 이미지의 고주파를 강조하며 텍스처 및 이미지 구조 분석을 한다. 마지막으로 ‘filter3’는 수평 2차 미분 (Horizontal Second-Order Derivative) 커널이며 수평 경계 추출한다. 3개의 커널은 학습되는 파라미터로써, 기존 컨볼루션 레이어를 통과하면서 학습되는 가중치로 대체한다.

$$filter1 = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & -1 & 2 & -1 & 0 \\ 0 & 2 & -4 & 2 & 0 \\ 0 & -1 & 2 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

$$filter2 = \begin{bmatrix} -1 & 2 & -2 & 2 & -1 \\ 2 & -6 & 8 & -6 & 2 \\ -2 & 8 & -12 & 8 & -2 \\ 2 & -6 & 8 & -6 & 2 \\ -1 & 2 & -2 & 2 & -1 \end{bmatrix}$$

$$filter3 = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & -2 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

그림 3. 학습 가능한 컨볼루션 커널 (LCK)

Fig. 3. Learnable Convolution Kernel (LCK).

(2) 이미지 조작에 강인한 ResNet-50

TOPAZ 데이터셋은 Upscaling 과정에서 여러 가지 이미지 조작에 대해 강인하게끔 알고리즘이 설계되었다. CNNDet에서는 딥페이크 데이터셋에 대해 여러 가지 조작을 가한 뒤, ResNet-50에 입력하여 학습했다. 해당 방법을 통해 원본 환경에서 발생하는 밝기, 노이즈, 카메라 해상도 등 물리적인 변화 발생에 대해 고려하고 영상을 저장하는 과정이나 전송 과정에서 용량을 줄일 때 압축과정에서 발생하는 노이즈를 해결하였다. 본 논문에서는 해당 모델을 사용하기 위하여 딥페이크 이미지 조작에 대해 강인하게 학습된 ResNet-50 모델을 가져와서 백본으로 사용한다.

이미지 증강 방식은 표 1와 같이 미리 증강 효과의 강도를 숫자로 정해둔 다음, 그 중 하나를 랜덤으로 선택하여 이미지 데이터셋에 기법을 적용하는 방식으로 진행한다.

(3) 데이터셋 전처리 및 학습 방법

사전에 제작한 데이터셋 4종의 학습과 테스트 데이터셋 비율을 8 : 2로 나누었다.

그림 4번은 초고해상화 탐지 알고리즘을 나타낸 것이다. 해당 그림과 같이 입력 이미지는 LCK를 통과하면서 각 커널의 특성에 따라 특징을 추출하고, 이 과정에서 학습된 파라미터가 업데이트 되고, 각 데이터셋들의 원본과 초고해상화의 특징을 사전에 추출하여 ResNet-50 모델에서 학습에 용이하게 사용한다. 이때,

표 1. 딥페이크 이미지 조작 탐지 모델 학습에 사용한 이미지 증강 기법 범위 및 강도

Table 1. Range and Intensity of Image Augmentation Techniques Used for Training the Deepfake Image Manipulation Detection Model.

Augmentation Technique	Range
Brightness Adjustment	-0.2 ~ 0.2
Contrast Adjustment	-0.2 ~ 0.2
Hue Adjustment	-15 ~ 15
Saturation Adjustment	-15 ~ 15
Gamma Adjustment	80 ~ 120
Augmentation Technique	Range
Resizing	(409, 409), (819, 819), (1228, 1228)
JPEG Compression	80, 85, 90, 91

딥페이크 이미지 조작에 대해 강인하게 사전 학습된 ResNet-50 모델은 LCK들의 출력 특징들을 이미지 조작 관점에서 분석하고 추출한다. 마지막으로 선형 레이어 (Linear layer)를 통과시켜 확률로 표시된 결과와 타겟 라벨간의 이진 분류 손실을 계산하여 초고해상화 탐지 모델을 업데이트한다.




그림 4. 초고해상화 탐지 모델 학습 알고리즘
Fig. 4. Training Algorithm of the Super-Resolution Detection Model.

III 실험

초고해상화 탐지 모델 평가 알고리즘은 학습된 모델을 불러온 뒤, 입력된 이미지에 대해서 이미지 전처리를 진행한다. 이후, 초고해상화 탐지 모델을 통해 도출된 결과에 대해 시그모이드 함수 (Sigmoid function)를 취하여 SR Score를 도출한다. 이때, SR Score가 0.5 이상이라면 초고해상화로 만들어진 가짜 이미지로 판별

하도록 알고리즘을 설계한다. 만약 입력 이미지가 2개 이상이라면 결과들을 count한 뒤, 입력 이미지의 라벨과 비교하여 정확도를 산출한다. 이때, 정확도는 식 1번과 같이 계산한다.

(1) 초고해상화 탐지 모델 정량적 결과 및 분석

이 섹션에서는 초고해상화 탐지 모델 성능을 테스트하고 정량적인 결과를 보여준다. 테스트시에는 GAN과 TOPAZ로 제작한 데이터셋의 테스트 데이터셋을 사용한다. 표 2는 테스트 데이터셋의 현황이며, 이를 통해 모델 평가를 진행하였다.

표 2. 모델 성능을 평가하기 위한 테스트 데이터셋의 초해상화 (SR) 및 원본 영상 (Real)의 개수

Table 2. Number of Super-Resolution (SR) and Original (Real) Videos in the Test Dataset for Model Performance Evaluation.

	EDSR	RCAN	SRGAN	TOPAZ
Real	450	450	450	450
Fake	450	450	450	450

논문에서 제안한 방식으로 학습된 모델을 불러온 뒤, 원본 이미지인지 초고해상화 알고리즘을 거친 이미지인지 판단한다. 비교 실험으로는 ImageNet으로 학습된 ResNet-50을 초고해상화 데이터셋에 대해 미세조정

Super-Resolution Detection Evaluation




그림 5. 초고해상화 탐지 모델 평가 알고리즘
Fig. 5. Evaluation Algorithm of the Super-Resolution Detection Model.

표 3. 초고해상화 탐지 모델의 테스트 데이터셋 정확도 (%)

Table 3. Test Dataset Accuracy (%) of the Super-Resolution Detection Model.

	ImagNet Pretrained ResNet-50	LCK + Manipulation ResNet-50
SRGAN	84	100
RCAN	81	100
EDSR	91.5	100
TOPAZ	99	100



그림 6. 초고해상화 탐지 모델의 데이터셋 별 혼동행렬

Fig. 6. Confusion Matrices by Dataset for the Super-Resolution Detection Model.

모델과 비교한다. 이때, 평가 지표로는 정확도를 사용한다. 정확도는 식 1번과 같이 계산한다.

$$Accuracy = \frac{\text{올바르게 예측한 개수}}{\text{전체 예측한 개수}} \times 100 \quad (1)$$

표 3번에서 볼 수 있듯이 논문에서 제안한 방식인 LCK와 Manipulation ResNet-50 모델을 통해 학습한 초고해상화 탐지모델이 ImageNet을 통해 사전학습한 ResNet-50 초고해상화 탐지 모델보다 우수한 성능을 보여주었다. 또한, 모든 테스트 데이터셋에서 100%의 성능을 기록하였다. 이는 학습 가능한 컨볼루션 커널이 1차적으로 초고해상화 데이터셋의 국소적인 정보를 가진 특징들을 추출하여 이미지 조작 사전학습 모델에 넘겨주었고, 해당 모델이 가지고 있는 여러 외부 요소 및 인공물에 대해 전역적인 특징까지 고려하면서 학습했기 때문에 높은 성능을 발휘했다고 볼 수 있다. 또한, 제안한 방식은 GAN과 같은 생성모델 뿐만이 아니라 기업

에서 제작한 툴에도 강인하게 작동하는 모습을 확인할 수 있다.

또한, 그림 6번에서 제시한 각 초고해상화 알고리즘별 테스트 데이터셋의 혼동행렬 (Confusion Matrix)를 통해 모든 초고해상화 및 원본 영상에서도 혼동없이 정확히 분류하는 모습을 확인할 수 있다. 이는 본 연구에서 제안하는 모델이, 초고해상화 영상이 상대적으로 적고 원본 영상이 더 많은 원본 세계 환경에서도 Long-tail 분포와 상관없이 분류를 정확하게 수행하는 것을 알 수 있다.

(2) 초고해상화 탐지 모델 정성적 결과 및 분석

이 섹션에서는 초고해상화 탐지 모델 성능을 테스트하고 정성적인 결과를 보여준다. 정성적인 결과를 보여주는 것은 gradient map으로 표현한다. gradient map은 모델이 입력 이미지의 어느 부위를 보고 예측을 했는지 원본 이미지와 원본 이미지 위에 heatmap을 겹치고 heatmap colorbar를 추가해서 시각화 된 이미지를 표시한다. 해당 값은 모델이 예측한 확률 값이 높아질수록 붉은색으로 표시된다. heatmap 생성 알고리즘은 초고해상화 탐지 알고리즘에는 ‘AblationCAM’^[11]를 사용하였다. 해당 알고리즘은 모델의 각 채널이 뉴런을 하나씩 제거하거나 무효화하고, 이에 따른 출력의 변화를 측정한다. 이를 통해 각 채널이 출력에 미치는 영향을 직접적으로 평가 가능하며, 더 정확한 채널 중요도를 반영하여 heatmap을 생성 가능하다. 그림 7번은 원본 이미지에서도 경계 부위에서 낮은 수준의 heatmap score가 관찰된다. 이는 LCK가 해당 경계를 참조 정보로 활용하였음을 의미하지만, 초고해상화 이미지에서 나타나는 것처럼 구조적으로 부자연스러운 형태의 경계나 텍스처의 불연속성 (Discontinuous)이 발견되지 않았기에, 최종적으로 초고해상화 여부 판단에는 주요 판단 요소로 고려되지 않았음을 의미한다.




그림 7. 초고해상화 탐지 모델 정성 평가 (원본)

Fig. 7. Qualitative Evaluation of the Super-Resolution Detection Model (Original).




그림 8. 초고해상화 탐지 모델 정성 평가 (초고해상화)
Fig. 8. Qualitative Evaluation of the Super-Resolution Detection Model (Super-Resolution).

반면에 그림 8번은 초고해상화 알고리즘을 통해 생성한 이미지에 대해서 모델이 평가한 결과이다. 눈썹, 입가 귀 주변 등 고주파 정보가 집중되는 경계 영역에서는 heatmap score가 높게 나타난다. 이는 LCK에서 사용된 커널이 각각의 용도에 따라 경계의 연속성 (Continuous), 텍스처의 블러 (Blur) 정도, 아티팩트 (Artifacts) 등의 특징을 모델이 감지했기 때문이다. 또한, 곡률 기반 커널을 통해 단순한 경계 검출 뿐만 아니라, 초고해상화 이미지에서 자주 나타나는 고주파 왜곡 패턴까지 효과적으로 감지하고 학습했음을 알 수 있다. 결과적으로, 본 논문에서 제안한 모델은 현실 영상과 초고해상화 영상 간의 구조적, 주파수 차이를 효과적으로 인식하고 분류하고 있으며 heatmap 분석을 통

해 그 해석 가능성 또한 확보됨을 확인할 수 있다.

(3) 모델 구성요소 제거 실험

이 섹션에서는 본 논문에서 제안하는 모델의 구성요소를 제거하여 비교 실험을 진행한다. 표 4에서는 LCK의 구성요소인 라플라시안 커널, 곡률 커널, 수평 2차 미분 커널 중 한 가지를 선택한 뒤, 기존 데이터셋을 사용하여 학습을 진행하고 초고해상화 및 원본 영상에 대한 분류 정확도를 측정하였다. 실험 결과, 세 커널을 각각 단독으로 적용한 경우, 제안하는 모듈 구성의 성능에 비해 분류 정확도가 최소 0.5%에서 최대 3.5%까지 감소하는 양상을 확인할 수 있다. 또한, LCK 모듈 자체를 사용하지 않고 학습한 모델은 단일 커널을 적용한 경우보다도 낮은 정확도를 보이고 있다. 이를 통해 모든 커널을 사용한 LCK 모듈 구성이 초고해상화 및 원본 영상간의 차이를 인식하고, 초고해상화 생성 방식에 상관없이 높은 분류 정확도를 달성하는 것을 확인할 수 있다.

표 5에서는 제안한 모델의 일반화 성능을 평가하기 위하여 기존 학습 방법을 토대로 학습 데이터셋에서 하나의 카테고리를 제거한 뒤, 모든 데이터셋에서 분류 정확도를 측정하였다. 실험 결과 RCAN, SRGAN 기법으로 제작된 데이터셋을 학습에서 제외하고 SRGAN으로 생성된 초고해상화 테스트 데이터셋에 대해 각각

표 4. 각 커널 종류 한 가지만을 사용하여 측정한 모델 정확도(%) 및 제안 방법 정확도 비교 실험
Table 4. Comparison of Model Accuracy (%) Measured Using Only One Kernel Type vs. Proposed Method Accuracy.

Kernel Type	EDSR		RCAN		SRGAN		TOPAZ	
	SR	Real	SR	Real	SR	Real	SR	Real
Laplacian	0.995	0.960	1.000	0.960	0.995	0.960	0.995	0.960
Curvature	0.985	0.985	0.990	0.985	0.970	0.985	0.990	0.985
Horizontal 2nd-order Derivative	0.990	0.965	0.995	0.965	0.985	0.965	1.000	0.965
w/o LCK	0.955	0.910	0.950	0.910	0.965	0.910	0.995	0.910
All Kernels Used	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000

표 5. 각 데이터셋 종류 한 가지만을 사용하여 학습한 모델의 정확도(%) 및 제안 데이터셋 정확도 비교 실험
Table 5. Comparison of Model Accuracy (%) Trained on a Single Dataset Type vs. Proposed Dataset Accuracy.

Dataset Type	EDSR		RCAN		SRGAN		TOPAZ	
	SR	Real	SR	Real	SR	Real	SR	Real
w/o EDSR	0.995	0.985	0.995	0.985	0.985	0.985	1.000	0.985
w/o RCAN	0.995	0.985	1.000	0.985	0.085	0.985	1.000	0.985
w/o SRGAN	0.995	0.985	1.000	0.985	0.080	0.985	1.000	0.985
w/o TOPAZ	0.995	0.880	1.000	0.880	1.000	0.880	0.615	0.880
All Datasets Used	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000

0.085, 0.080 이라는 낮은 분류 정확도를 기록한 반면, 동일 조건에서 원본 영상에 대해서는 높은 분류 정확도를 유지하는 결과를 확인할 수 있다. 이러한 결과는 PSNR 기반 최적화 알고리즘인 RCAN으로 생성된 데이터가 모델 학습시 분포의 다양성을 확보하는 데 일정 부분 기여하며, 해당 데이터가 제거될 경우 perceptual loss^[15] 기반 최적화 알고리즘인 SRGAN과 같은 특정 기법의 분포를 일반화하는 데 어려움이 발생할 수 있음을 의미한다. 또한, TOPAZ와 같이 알고리즘이 비공개된 알고리즘에 대해서는 극단적인 성능하락은 보이지 않으나, 본 연구에서 제시한 성능보다는 떨어지는 모습을 보이고 있다. 이러한 결과는 제안하는 모델이 높은 성능을 확보하기 위해 다양한 초고해상화 기법을 반영한 학습 데이터가 일정 수준 이상으로 포함되어야 한다는 것을 알 수 있다.

IV. 결 론

본 논문에서는 GAN 기반 초고해상화 알고리즘 및 상용 툴(TOPAZ Labs)로 제작된 초고해상화 이미지를 포함하는 다양한 데이터셋을 구축하고, 이를 구별해낼 수 있는 초고해상화 이미지 탐지 모델을 제안하였다. 제안 모델은 학습 가능한 컨볼루션 커널(Learnable Convolution Kernel, LCK)을 통한 국소적인 특징 추출과 이미지 조작에 강인하게 사전학습된 ResNet-50 기반의 백본 모델을 결합함으로써, 기존 ImageNet으로 사전학습한 ResNet-50 모델 대비 뛰어난 분류 성능을 확보하였다. 특히, 제안한 방법론은 GAN 기반 초고해상화 알고리즘뿐만 아니라 상용 초고해상화 툴을 통해 생성된 이미지에도 일관되게 우수한 탐지 성능을 보이며, 전체 테스트 데이터셋에서 100% 정확도를 달성하였다.

이는 LCK를 통해 이미지 내 세밀한 화질 개선 흔적 및 로컬 패턴을 효과적으로 추출하고, 이를 다양한 조작 환경에 적응적으로 대응하도록 사전학습된 백본 모델에 전달함으로써 전역적인 특징까지 분석할 수 있었기 때문이다. 또한, 정성적인 결과 분석 (Gradient map 시각화)을 통해 제안 모델이 사람 얼굴 영역의 엷거나 텍스처와 같은 중요한 세부 정보들을 활용하여 초고해상화 이미지와 원본 이미지를 구별하고 있음을 확인하였다. 이러한 결과는 기존 딥페이크 탐지 모델들이 단일 알고리즘이나 특정 데이터셋에 특화되어 있는 문제점을 넘어, 다양한 초고해상화 기법과 현실적인 이미지

조작 상황에도 높은 적응력을 갖춘 탐지 모델의 필요성을 강조한다.

본 연구를 통해, 향후 딥페이크 및 초고해상화 이미지 탐지 분야에서 보다 현실적이고 일반화된 환경을 고려한 새로운 탐지 모델 개발에 기여할 수 있을 것으로 기대한다. 향후 연구에서는 더 다양한 조작 요소나 멀티모달(Multi-modal) 정보 융합 및 비디오 단위 분석 등을 통해, 변화하는 영상 처리 환경에서도 안정적이고 강인한 탐지 모델을 구축하는 방향으로 발전할 수 있을 것이다.

REFERENCES

- [1] J. H. Park and M. H. Sunwoo, "Histopathology image super resolution using generative adversarial network," *J. Inst. Electron. Inf. Eng.*, vol. 59, no. 8, pp. 55-60, Aug. 2022, doi: 10.5573/ieie.2022.59.8.55.
- [2] Li, Lin, et al. "Super-resolution reconstruction of high-resolution satellite ZY-3 TLC images." *Sensors* 17.5 (2017): 1062.
- [3] Goodfellow, Ian, et al. "Generative adversarial networks." *Communications of the ACM* 63.11 (2020): 139-144.
- [4] Wang, Sheng-Yu, et al. "CNN-generated images are surprisingly easy to spot... for now." *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2020.
- [5] He, Kaiming, et al. "Deep residual learning for image recognition." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016.
- [6] Deng, Jia, et al. "Imagenet: A large-scale hierarchical image database." *2009 IEEE conference on computer vision and pattern recognition*. Ieee, 2009.
- [7] Ledig, Christian, et al. "Photo-realistic single image super-resolution using a generative adversarial network." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017.
- [8] Lim, Bee, et al. "Enhanced deep residual networks for single image super-resolution." *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*. 2017.
- [9] Zhang, Yulun, et al. "Image super-resolution using very deep residual channel attention

- networks." *Proceedings of the European conference on computer vision (ECCV)*. 2018.
- [10] Rossler, Andreas, et al. "Faceforensics++: Learning to detect manipulated facial images." *Proceedings of the IEEE/CVF international conference on computer vision*. 2019.
- [11] Ramaswamy, Harish Guruprasad. "Ablation-cam: Visual explanations for deep convolutional network via gradient-free localization." *proceedings of the IEEE/CVF winter conference on applications of computer vision*. 2020.
- [12] Frank, Joel, et al. "Leveraging frequency analysis for deep fake image recognition." *International conference on machine learning*. PMLR, 2020.
- [13] J. J. Sim, W. J. Jung, H. S. Yang, B. G. Han, Y. C. Cho, and Y. S. Moon, "Nuclei segmentation utilizing CNN and guide image," *J. Inst. Electron. Inf. Eng.*, vol. 55, no. 9, pp. 83–91, Sep. 2018, doi: 10.5573/ieie.2018.55.9.83.
- [14] B. Y. Heo and B. C. Song, "Learning-based super resolution for text images," *J. Inst. Electron. Inf. Eng.*, vol. 52, no. 4, pp. 175–183, Apr. 2015
- [15] J. Johnson, A. Alahi, and L. Fei-Fei, "Perceptual losses for real-time style transfer and super-resolution," in **European Conference on Computer Vision**, Cham: Springer, 2016, pp. 694–711.

저 자 소 개



최 기 윤(비회원)
2025년 9월 중앙대학교
첨단영상대학원
영상공학 전공
(영상학 석사)

<주관심분야: 딥러닝, 딥페이크, 컴퓨터비전>



윤 성 빈(비회원)
2008년 8월 중앙대학교
첨단영상대학원
디지털/과학사진 전공
영상학 석사 졸업
2011년 8월~현재 대검찰청
과학수사부 법과학분석과
재직

<주관심분야: 영상분석, 딥페이크>



최 종 원(정회원)
2012년 KAIST 전기전자공학과
공학학사
2014년 KAIST 전기전자공학과
공학석사
2018년 서울대학교
전기정보공학부 공학박사

2018년 6월~2020년 3월 삼성 SDS,
AI Research Center,
Research Scientist

2020년 3월~2024년 2월 중앙대학교
첨단영상대학원 조교수

2024년 3월~현재 중앙대학교 첨단영상대학원
부교수

<주관심분야: 딥페이크, 컴퓨터비전>