



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.


다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

데이터사이언스석사 학위논문

Retrieval-Augmented Generation을 통한 효율적인 문서 검색

2026 년 2 월

서울대학교 데이터사이언스대학원
데이터사이언스학과 데이터사이언스학전공
김 용 민



Retrieval-Augmented Generation을 통한 효율적인 문서 검색

지도교수 이 상 원

이 논문을 데이터사이언스석사 학위논문으로 제출함

2025 년 12 월

서울대학교 데이터사이언스대학원
데이터사이언스학과 데이터사이언스학전공
김 용 민

김 용 민의 석사 학위논문을 인준함

2026 년 1 월

위 원 장 _____ 정 형 수 _____ (인)

부위원장 _____ 이 상 원 _____ (인)

위 원 _____ 김 태 섭 _____ (인)



서울대학교
SEOUL NATIONAL UNIVERSITY

국문초록

최근 생성형 인공지능(Generative AI)의 급격한 발전으로 지식 경영의 패러다임이 변화하고 있으나, 기업 내부의 각종 보고서 등 비정형 문서는 보안 문제와 비용 제약으로 인해 외부 API 기반의 온라인 대규모 언어모델(LLM)을 직접 활용하기 어려운 실정이다. 이에 본 연구는 오프라인 언어모델을 활용하여 보안과 비용 제약을 해결하면서, 실무적으로 사용 가능한 검색 성능을 갖는 로컬PC 기반의 금융 도메인 특화 RAG(Retrieval-Augmented Generation) 시스템을 제안한다.

본 연구에서는 기업에서 생산하는 보고서 자료와 유사한 환경을 갖추기 위해 금융감독원, 금융위원회, 한국은행의 보고서 및 보도자료 등 총 1,295건의 문서를 수집하고, 이 문서들을 활용하여 금융 특화 벤치마크 데이터셋을 구축하였다. 검색 성능 최적화를 위해 기업 문서의 특징인 개조식 구조를 반영한 전용 청킹(Chunking) 기법을 설계하였으며, 금융권역에 특화된 임베딩 모델 생성을 위해 금융 용어사전을 활용, BGE-M3 임베딩 모델을 미세조정(Fine-tuning)하였다. 나아가 의미 기반 검색(Semantic Search)과 키워드 검색(BM25)을 결합한 하이브리드 검색 전략을 적용하여 문서 검색의 정확도를 제고하였다.

연구 결과, 오프라인 하이브리드 RAG시스템은 문서검색 성능을 나타내는 Hit@1 지표에서 0.535를 기록하여, 최신 온라인 상용 모델인 VoyageAI 기반 시스템(0.554) 대비 약 96.6% 수준의 검색 성능을 달성하였다. 또한, 로컬PC 자원의 제약을 극복하고 응답 속도를 개선하기 위해 MatKV(Materialized Key-Values) 기법을 적용한 결과, 문서 검색의 정확도를 유지하면서도 질의당 평균 소요 시간을 9.892초에서 2.536초로 획기적으로 단축하여 온라인 voyage 모델의 평균 소요시간인 1.930초에 버금가는 실시간 응답성을 확보하였다.

본 연구는 외부망 연결이 제한된 기업 내부 환경에서도 오프라인 LLM과 최적화된 검색 기법을 통해 상용 서비스 수준의 금융 문서 검색 시스템을 독자적으로 구축할 수 있음을 실증적으로 제시하였다는 데 의의가 있다.

주요어: 검색증강생성(RAG), 금융 도메인 특화, 오프라인 LLM, 하이브리드 검색, MatKV, 미세조정(fine-tuning)

학번: 2024-26529

목 차

제 1 장 서 론	1
제 1 절 연구의 목적과 배경	1
제 2 절 연구의 내용	2
제 2 장 선행 연구	4
제 1 절 FACTS : 기업에서 RAG 챗봇 도입시 고려할 사항	4
제 2 절 임베딩 모델의 미세조정을 통한 성능 향상	6
제 3 장 연구 방법	7
제 1 절 금융 특화 벤치마크 데이터셋 구축	7
제 2 절 RAG시스템 구축	8
1. 오프라인 LLM 기반(실험군)	8
2. 온라인 LLM 기반(대조군)	9
제 3 절 RAG시스템별 성능 비교	10
1. 청킹 기법에 따른 성능 점검	10
2. 임베딩 모델 최적화: 미세조정(fine-tuning)	10
3. 검색 방식 최적화: 하이브리드 검색	12
4. MatKV 기법 적용에 따른 성능 점검	14
제 4 절 결과 분석 및 시사점 도출	15
제 4 장 연구 결과 및 분석	16
제 1 절 평가 지표 설정	16

1. 정답 문서 검색 성능 평가지표	16
2. 질의에 대한 답변의 정확성 평가지표	17
3. 통합 평가지표	17
4. 질의별 평균 소요시간	18
제 2 절 청크 크기에 따른 RAG시스템의 성능 변화	19
1. 청크 크기에 따른 문서 검색 성능 비교	19
2. 청크 크기에 따른 답변의 정확도	20
3. 결론	21
제 3 절 온라인 LLM 성능 점검	21
제 4 절 오프라인 LLM 성능 점검	22
제 5 절 종합 성능 비교 분석	24
1. 온라인 vs 오프라인 LLM 성능 비교	24
2. 검색 성능 저해 요인 분석: 데이터 특성을 중심으로	25
3. MatKV 기법 적용에 따른 성능 점검	27
제 5 장 결 론	29
제 1 절 고 찰	29
제 2 절 향후 과제	29
참고문헌	32
Abstract	34

표 목 차

표 3.1	기관별 사용된 문서 개수	7
표 3.2	질의 응답 및 출처 예시	8
표 4.1	Chunk Size별 문서 검색 성능 비교	19
표 4.2	Chunk Size별 답변 생성 및 통합 성능 비교	20
표 4.3	OpenAI와 VoyageAI 임베딩 모델 성능 측정	22
표 4.4	오프라인 LLM을 활용한 RAG 시스템 성능 비교	22
표 4.5	온라인(VoyageAI)과 오프라인 제안 모델(Hybrid) 성능 비교 . .	24
표 4.6	LLM 모델별, MatKV 기법 적용별 성능 비교	27

그림 목 차

그림 2.1	다양한 모델 간의 NVHelp 답변 품질 및 대기 시간 측정 비교	5
그림 3.1	금융 특화 벤치마크 데이터셋 구축 개요	8
그림 3.2	기업 보고서에서 주로 쓰이는 개조식 문장의 예시	11
그림 5.1	금융결제원 등에서 진행하는 금융말뭉치 시범사업	31

제 1 장 서 론

제 1 절 연구의 목적과 배경

최근 생성형 인공지능(Generative AI)의 급격한 발전은 “지식 경영(knowledge management)”의 패러다임을 새롭게 재편하고 있다. 기업 내부에는 각종 보고서 뿐만 아니라 공시자료, 내부 규정 등 규격화되지 않은 비정형 문서가 방대하게 축적되어 있으나, 전통적 키워드 검색만으로는 문서 내용의 문맥적 의미를 정확히 파악할 수 없어 정보를 제대로 활용하지 못하는 한계가 있다. 이에 시스템 사용자는 관련 문서를 장시간 수작업으로 선별·요약해야 하고, 결정적 근거가 문서의 다른 단락이나 별첨·표에 산재해 있는 경우 탐색 비용과 소요 시간이 급격히 증가하게 된다. 반면 의미 기반 검색(semantic search)은 문맥적 유사성을 벡터 수준에서 검증함으로써 표현이 달라도 의미가 같은 표현을 정확하게 검색하고, 이렇게 검색된 다수의 정보들을 종합하여 정확한 답변을 제공할 수 있는 잠재력을 지니고 있다. 이러한 의미 기반 검색을 통해 기존과는 다른 새로운 가치를 창출하려는 기술적 요구가 증대되고 있다.

이러한 흐름 속에서 본 연구는 Retrieval-Augmented Generation(이하 “RAG”) 기법을 활용하여 특정 업권, 특히 금융 분야에 특화된 문서검색 시스템을 제안하는 것을 주제로 한다. 기존의 키워드 기반 검색 시스템은 대규모 문서 집합에서 사용자가 의도하는 정보를 정확하게 추출하는 데 한계를 지니며, 특히 금융 보고서와 같은 도메인 특화 문서의 경우 전문 용어와 복잡한 구조적 정보(표, 그래프, 그림 등)로 인해 검색 효율성이 저하되는 문제가 존재한다. 더불어 기업에서 생산·축적되는 문서는 보안적 민감성이 높아, 외부 응용 프로그램 인터페이스(Application Programming Interface, 이하 “API”) 기반의 온라인 대규모 언어모델(이하 “LLM”)

과 임베딩 모델(embedding model)을 직접 활용하기 어려운 제약이 따른다. 실제로 다수의 기업은 개인정보, 회사 기밀 등을 담고 있는 대외비 문서가 학습에 이용되거나 외부로 유출될 위험성을 우려하여 사내 규정 등을 통해 온라인 LLM의 사용을 제한하고 있다.

이에 본 연구는 전통적인 키워드 기반 검색의 한계를 극복하기 위하여 의미 기반 검색을 기본으로 한 RAG 기법을 활용하여 컴퓨터 저장장치에 축적된 방대한 문서로부터 필요한 정보를 보다 효율적이고 정확하게 검색할 수 있는 체계적 방법론을 제시하고자 한다. 특히, 보안과 비용 제약으로 인해 온라인 LLM을 활용하기 어려운 환경에서도 적용 가능한 오프라인 LLM을 기반으로 하는 문서검색 시스템을 실증적으로 제안한다. 궁극적으로, 이러한 오프라인 LLM을 기반으로 하는 RAG 검색시스템이 단순한 기술적 대안에 그치지 않고, 기업·금융기관 등 특정 업권에서 실질적 가치와 경쟁력을 갖춘 특화형 문서검색 시스템으로 발전할 수 있음을 실증적으로 제시하는 것을 목적으로 한다.

제 2 절 연구의 내용

본 연구는 온라인 LLM과 오프라인 LLM을 병행 비교하면서, 보안·비용 제약 환경에서도 안정적으로 작동할 수 있는 도메인 특화 RAG 기반 문서검색 시스템을 제안한다. 특히 한국 기업 환경의 특수성—부서별 문서 관리 관행 및 중간 산출물까지 포함한 문서 검색의 필요성—을 반영하여, 기업의 서버 뿐만 아니라 직원이 업무에 활용하는 로컬PC에서도 안정적으로 작동할 수 있도록 소규모 오프라인 LLM 모델을 활용한 시스템을 설계·구축한다. 나아가, 검색된 도메인 특화 정보를 LLM이 더욱 정확하게 이해한 상태에서 답변을 생성하도록 만드는 ‘도메인 특화 RAG를 위한 LLM 미세조정(fine-tuning for domain-specific RAG)’ 기법을 적용하여 검색 성능과 속도의 동시 개선을 시도하고, 보다 높은 정확도를 이끌어내기 위하여 의미 기반 검색과 전통적 키워드 검색을 결합한 하이브리드

검색 기법을 적용하여 문서 검색의 정확도가 어느 정도로 향상되는지 실증적으로 검증한다. 추가로, MatKV(Materialized Key-Values) 기법을 적용하여 검색 속도 향상 여부를 확인한다. 이를 통해 통상적으로 온라인 LLM 대비 성능이 낮다고 평가받는 오프라인 LLM의 한계를 보완하고, 온라인 LLM 대비 어느 정도의 성능 경쟁력을 확보할 수 있는지 실험적으로 규명하고자 한다.

제 2 장 선행 연구

제 1 절 FACTS : 기업에서 RAG 챗봇 도입시 고려할 사항

Akkiraju 등(2024)[1]은 기업 환경에서 RAG 기반 챗봇을 구축·운영하면서 마주치는 핵심 과제를 총괄적으로 정리하고, 이를 토대로 FACTS 프레임워크(Freshness, Architecture, Cost, Testing, Security)로 체계화한다(이하 “FACTS 논문”). 각 항목별 요지는 다음과 같다.

- **F-Freshness(최신성)**: RAG 기반 LLM 챗봇의 고정된 지식(저장된 문서를 기반으로 하므로)으로 인한 최신성·환각 문제를 완화하기 위해 메타데이터 부여, 청킹 전략, 질의 재작성, 재랭킹, 하이브리드 검색 등 RAG 파이프라인 내에서 영향도가 큰 고영향 제어지점을 정밀 조정할 것을 제안한다.
- **A-Architecture(아키텍처)**: 급변하는 LLM 기술을 고려하여 플러그형(modular) 공통 플랫폼을 권장한다.
- **C-Cost(비용)**: 대형 상용 LLM은 누적비용과 답변 지연이 크다는 지점을 지적하면서, 소형 오픈소스LLM+최적화 추론 조합이 근접한 정확도와 더 나은 지연을 보이는 실증을 제시한다.
- **T-Testing(평가·검증)**: LLM을 통한 자동 평가 시스템 도입시 평가에 내재된 편향이 강화될 수 있으므로 사람의 추가 검증이 필요하며, LLM을 통한 자동 평가는 보조적으로 활용할 것을 제안한다.
- **S-Security(보안)**: 문서 보안, 민감정보 필터링 등이 핵심으로, 생성물이 원문 맥락을 벗어나 파생 위험을 가질 수 있으므로 답변에 사용된 문서의

출처를 명확히 명시하는 것을 필수적인 안전장치로 규정한다.

FACTS 논문에서는 모델의 응답 품질이 청킹 방식에 크게 의존한다고 하면서 정확한 답을 얻기 위한 올바른 구성을 찾아내기 위해 다양한 청킹 전략 등을 제시하였다. 이는 본 연구에서 제안하고 있는, 개조식 문서 형태에 특화된 전용 청킹 방식과 구성을 찾기 위해 줄바꿈 및 기호 기반의 청킹을 시도하고 일부 오버랩을 진행하는 등의 설계가 실제 모델 응답 품질 제고에 효용이 있음을 뒷받침한다.




그림 2.1: 다양한 모델 간의 NVHelp 답변 품질 및 대기 시간 측정 비교

한편, FACTS 논문은 그림 2.1과 같이 비용 측면에서 소형 오픈소스 LLM이 다수의 케이스에서 상용 대형 LLM 대비 유사한 정확도와 더 낮은 지연 시간을 가질 수 있음을 보고하고 있다. 이는 오프라인 소형 LLM과 온라인 대형 LLM의 비교 설계, 임베딩 효율화 프레임워크를 구성하고자 하는 본 연구의 방향성과 부합한다.

제 2 절 임베딩 모델의 미세조정을 통한 성능 향상

Gao 등(2023)[2]은 RAG 시스템에서 검색 성능은 최종 결과물의 품질을 결정하는 핵심적인 요소라고 지적하면서, 임베딩 모델이 질의와 문서의 의미를 얼마나 정확하게 벡터로 표현하는지가 검색의 성패를 좌우한다고 논한다. 그러나 범용 데이터로 사전 훈련된 임베딩 모델은 특정 전문 분야에서 세부적인 의미 관계를 포착하는 데 한계가 있음을 지적하면서, 특정 분야에서 RAG 시스템의 성능을 극대화하기 위해서는 임베딩 모델의 미세조정이 필수적이라고 말하고 있다.

특히 의료, 법률, 금융 등 고도의 전문 용어가 사용되는 특정 도메인 환경에서는 기존 임베딩 모델이 도메인에서 요구되는 전문 용어의 미묘한 의미 차이를 구분하지 못하여 검색 정확도가 저하될 수 있다는 한계를 가진다. 용어의 다의성, 도메인 내에서 통용되는 각종 약어·줄임말 등이 검색의 정확도를 떨어뜨릴 수 있으며, 범용 임베딩 모델은 이러한 요소를 충분히 감안하기 어려워 의미가 가까운 문서들을 정확히 검색하기 어려운 문제가 있다.

Gao 등은 이러한 경우 해당 분야에 특화된 데이터셋을 사용하여 임베딩 모델을 미세조정함으로써 모델이 도메인 특화 지식을 학습하고 보다 정확한 의미적 유사도 측정을 수행하도록 만들 수 있다고 언급한다. 이는 금융에 특화된 분야에서 RAG 시스템의 검색 성능을 실질적으로 향상시키기 위한 핵심 전략으로, 금융에서 주로 사용되는 용어의 정의 정보 등을 활용하여 임베딩 모델 미세조정을 진행하고자 하는 본 연구의 방향성과 일치한다.

제 3 장 연구 방법

본 연구는 특정 업권, 특히 금융 분야에 특화된 문서검색 시스템을 구축하고, 이를 온라인 및 오프라인 LLM 환경에서 비교·분석함으로써 RAG 기반 검색의 효율성과 실용성을 검증하는 것을 목적으로 한다. 이를 위해 다음과 같은 연구 절차와 방법론을 적용하였다.

제 1 절 금융 특화 벤치마크 데이터셋 구축

금융 도메인에 특화된 문서검색 시스템을 평가하기 위한 벤치마크 데이터셋을 구축하였다. 데이터셋은 금융감독원, 금융위원회, 한국은행 등 공신력 있는 기관에서 발간하는 보고서, 보도자료, 정책자료 등을 수집·정제하여 구성하였다. 벤치마크 데이터셋은 2024년 7월부터 2025년 4월 기간 중 각 기관에서 생성된 금융 관련 문서 총 1,295개를 대상으로 하였다. 해당 문서는 PDF·HWP·HWPX·DOCX 등 다양한 포맷으로 구성되어 있으며, 이를 일괄적으로 PDF로 변환 후 이를 기준으로 분석을 진행하였다.

표 3.1: 기관별 사용된 문서 개수

항목	금융감독원	금융위원회	한국은행	계
문서 개수	825	134	336	1,295

PDF파일 변환시에는 문서 내의 표 등 텍스트로 이루어진 비정형 데이터를 모두 포함하도록 전처리 과정을 설계하였으며, 이후 문서별로 질의와 모범답변 형태의 실험용 QA 라벨을 작성하고 이를 평가에 활용하였다. 문서별로 1~2개의

QA set을 생성하여 총 2,214개의 QA set을 구축하였다.




그림 3.1: 금융 특화 벤치마크 데이터셋 구축 개요

표 3.2: 질의 응답 및 출처 예시

	질의응답 A	질의응답 B
question	2024년도 금융복합기업집단으로 지정 되기 위한 자산총액 기준은 얼마인가?	2025년도 금융체계상 중요한 은행 및 은행지주회사로 선정된 기관은 무엇 인가?
gold_answer	5조원 이상	신한금융지주, KB금융지주, 하나금 유지주, 우리금융지주, 농협금융지주, KB국민은행, 우리은행, 신한은행, 하 나은행, 농협은행이다.
source	240710(보도자료) 2024년도 금융복 합기업집단 지정.pdf	240710(보도자료) 2025년도 금융체 계상 중요한 은행 은행지주회사 및 금융체계상 중요한 금융기관 선정 결 과.pdf

제 2 절 RAG시스템 구축

1. 오프라인 LLM 기반(실험군)

보안성과 비용 효율성을 고려하여 오프라인 환경에서 구동 가능한 LLM을 활용
한 RAG 시스템을 구축하였다. 구체적으로는 로컬PC에서도 원활한 동작이 가능한

소형 LLM 모델인 Llama3.1:8B 모델을 기반으로 로컬 환경에서 동작하는 RAG 시스템을 설계하였다. 임베딩 모델은 범용 멀티모달·멀티벡터 검색이 가능하면서 한국어를 원활하게 지원하는 BGE-M3를 사용하였다. BGE-M3 모델은 하나의 모델로 (a) 밀집(dense), (b) 어휘/희소(lexical/sparse), (c) 멀티벡터(ColBERT 류) 검색을 모두 지원하는 “Multi-Functionality”, 한국어를 포함한 다양한 언어에 대한 표현력이 뛰어난 “Multi-Linguality”가 가능한 모델[3]로, 이는 본 연구에서 적용할 하이브리드 검색 방법을 적용하기에 알맞고, 또한 다양한 영어 약어 등이 포함된 보고서를 정확한 의미로 파악 가능하다고 판단하여 BGE-M3 임베딩 모델을 기본으로 채택하였다.

2. 온라인 LLM 기반(대조군)

오프라인 LLM 기반 RAG시스템과 유사하게 OpenAI의 ChatGPT에서 지원하는 gpt-4o-mini LLM 모델을 활용하여 RAG 시스템을 구현하고 이를 대조군으로 설정하였다. 온라인 LLM 기반의 RAG 시스템은 상대적으로 대규모 모델의 성능과 최신 데이터 접근성을 바탕으로 고성능 검색이 가능하다는 장점이 있으므로, 오프라인 시스템과의 비교를 통해 성능 격차를 정량적으로 분석하였다. 분석에 사용된 임베딩 모델은 OpenAI 전용 임베딩 모델인 text-embedding-3-small을 기본으로 설정하여 진행하였다.

추가로, 2025년 5월 공개된 금융 특화 임베딩 모델인 voyageAI사의 voyage-3.5 모델을 활용하여 온라인 기반 RAG시스템의 성능을 점검하였다. 이 모델의 핵심 장점은 (i) 동급 대비 우수한 가격-성능 비율, (ii) 유연한 차원/양자화(quantization)로 인한 저장·조회 비용 절감, (iii) 장문 컨텍스트(32K 토큰) 지원과 다국어(26개 언어) 범용성으로, 실제 voyageAI사의 자체 실험결과에 의하면 OpenAI사의 OpenAI-v3-large 모델 대비 100개 데이터셋 평균 NDCG@10이 8.26%p 높고 비용은 약 2.2배 낮은 것으로 나타났다. 또한 voyage-3.5는 한국어를 포함한 26개

언어에서의 검색 성능을 별도 평가로 제시하고 있는데, 한국어 기준으로 voyage-3.5 모델(93.88%)이 OpenAI-v3-large 모델(83.63%) 대비 성능이 높아[4] 한국어 중심의 기업 내부 자료를 다루는 RAG시나리오에 적합할 것으로 판단하였다.

제 3 절 RAG시스템별 성능 비교

1. 청킹 기법에 따른 성능 점검

본격적인 성능 비교 실험에 앞서, 문서 임베딩에 활용되는 청크(chunk)의 크기와 방법에 따른 RAG시스템의 효율성, 정확도와 제반 비용을 분석하고, 이를 통해 사용자 질의에 제일 적합한 답변을 제시하고 정확한 문서를 찾는 청크 크기 등의 조건을 구체적으로 확인하였다.

본 연구에 활용된 문서는 일반 기업에서 통상적으로 작성되는 개조식 문서 형태를 띠고 있으며, 문서의 가독성·간결성·효율성을 높이기 위해 네모, 동그라미, 별표 등의 기호를 사용하여 주요 내용을 항목별로 구분하고, 각 항목은 줄바꿈을 통해 시각적으로 구별되도록 작성되어 있다. 이러한 문서의 구조적 특성에 착안하여, 본 연구에서는 줄바꿈 기호를 기준으로 문서를 청킹(chunking)하고, 청크 간 일정 부분의 중첩(overlap)을 적용함으로써 문맥적 연결성을 유지하도록 하는, 기업 문서구조에 특화된 전용 청킹 방식을 설계·적용하였다. 이를 통해 RAG 시스템이 문장의 흐름을 단절 없이 반영할 수 있도록 하여 검색 및 응답의 품질 제고에 효용이 있음을 실증적으로 점검하였다.

2. 임베딩 모델 최적화: 미세조정(fine-tuning)

금융권역은 다른 산업들과는 달리 금융권역에서만 통용되는 특수한 전문용어와 약어, 규제·정책적 표현이 빈번히 사용되며, 이러한 금융권역의 특수성을 범용적인 임베딩 모델로는 충분히 반영하기 어려운 한계가 있다. 이에 본 연구는 이러한 한계를 극복하기 위하여 금융감독원이 보유하고 있는 「금융용어사전」

< PF 사업성 평가 관련 그간의 경과 >

① 사업성 평가기준 개선 ('24.4월~6월)

- **(개선안 마련)** 부동산PF 사업성 평가의 객관성·합리성 제고를 위한 제도개선 방안* 마련 (5.14일 보도)
- * ① 사업성 평가체계 세분화 : 3단계 → 4단계(양호보통유위부실우려), ② 평가기준 객관화구체화 : 본PF, 브릿지론 구분하여 핵심 위험요인을 반영 ③ 사업성 부족 사업장 신속한 정리 및 금감원 점검 강화 등
- **(준업권 평가기준 개선)** 금융업·건설업계 설명회 개최 및 의견수렴 등을 거쳐, 각 금융업권은 新 사업성 평가기준(6.7일 확정)을 모범규준 등에 반영

그림 3.2: 기업 보고서에서 주로 쓰이는 개조식 문장의 예시

자료를 활용하여 BGE-M3 임베딩 모델의 미세조정을 수행하였다. 사전이나 용어집에 포함된 정의 정보를 활용하여 단어 임베딩의 의미적 표현력을 강화하려는 시도는 지속적으로 이루어져 왔다. Bosc and Vincent(2018)[5]은 사전 정의문의 재구성을 통한 오토인코딩(Auto-encoding) 방식을 통해, 사전 데이터가 범용 임베딩 모델의 의미적 유사성(Semantic Similarity)을 효과적으로 보정할 수 있음을 입증하였다. 본 연구는 이러한 사전 데이터의 효용성을 활용하되, 검색 성능 최적화에 더 직접적으로 기여하는 대조 학습(Contrastive Learning) 기반의 미세조정 기법을 적용하여 금융 특화 임베딩 모델을 구축하였다. 미세조정의 목표는 ① 금융 권역에서 주로 쓰이는 표현을 임베딩 모델에 정밀하게 반영하여 의미적 근접성을 향상시키고, ② 계산성능과 메모리 제약 하에서 검색 정확도를 향상시키는 것이다.

학습 데이터셋 구축 및 전처리

학습 데이터로 사용된 금융감독원의 「금융용어사전」 데이터는 (용어, 정의) 쌍으로 구성되어 있으며, 이를 RAG시스템의 질의-문서(query-passage) 검색 환경에 적합하도록 변환하는 과정을 거쳤다. 해당 사전은 총 538개 금융용어를 정의하고 있으며, 실제 사용자의 다양한 질문 패턴을 반영하기 위해 5가지 유형의 질의 템

플릿(“용어란 무엇인가?”, “용어의 뜻은?” 등)을 추가로 적용하여 용어당 총 6쌍의 학습 샘플을 생성하였다. 또한 모든 질의에는 접두어 ‘query: ’, 정의에는 ‘passage: ’를 명시하여 BGE-M3 임베딩 모델이 학습 데이터에서 질의와 정의의 역할을 명확히 구분할 수 있도록 하였다.

손실함수 및 학습 프로세스

미세조정에 쓰인 손실함수로는 *Sentence-Transformers* 프레임워크의 *Multiple Negatives Ranking Loss*(MNRL, 이하 “MNR 손실함수”)를 채택하였다. MNR 손실함수는 학습 데이터 배치 내에서 정답 쌍(query_i, passage_i)에 대해, 배치 내의 다른 샘플을 모두 부정 예제(negative sample)로 간주하여 학습하는 ‘In-batch Negatives’ 방식을 사용[6]하고 있다. 이 방식은 제한된 GPU 메모리 자원 하에서도 명시적인 부정 예제를 별도로 구축하는 비용 없이 대규모의 부정 예제를 확보할 수 있어 학습 효율성을 극대화할 수 있다는 장점이 있다.

본 연구는 MNR 손실함수를 통해 임베딩 공간 내에서 질의와 정답 문서 간의 유사도는 높이고 오답 문서와의 거리는 멀어지도록 학습을 진행하면서, 충분한 배치 크기를 확보하여 검색 모델의 판별력을 강화하는 데에 중점을 두었다. 이를 통해 사전형 정의 문서에 내재된 금융 도메인 용어의 의미 관계가 임베딩 공간에 보다 선명히 반영되고, 동일 시스템 자원 하에서 RAG시스템의 답변 정확도와 문서 검색 정확도가 향상될 수 있도록 하였다.

3. 검색 방식 최적화: 하이브리드 검색

금융 도메인의 특성상 질의(Query)는 문맥적인 의미를 내포하는 동시에, 특정 수치나 고유명사(예: ‘휴면예금’, ‘2024년 7월’ 등)와 같은 정확한 키워드 매칭을 요구하는 경우가 빈번하다. 따라서 본 연구에서는 단일 검색 기법의 한계를 극복하고 검색 정확도를 극대화하기 위하여, 의미론적 유사성을 포착하는 의미 기반

검색(semantic search)과 어휘적 일치를 강조하는 키워드 검색(keyword search)을 결합한 하이브리드 검색 전략을 적용하였다. 특히, 의미 기반 검색과 BM25(Best Matching 25) 키워드 검색 알고리즘의 조합은 상호 보완적인 강점 덕분에 우수한 성능[7]을 보일 수 있어, 본 연구에서는 BM25 알고리즘을 사용하여 하이브리드 검색 기법을 구현하였다.

의미 기반 검색

질의의 의도와 문맥을 파악하는 데 유리한 검색 기법으로, 본 연구에서는 앞서 미세조정된 BGE-M3 모델을 사용하여 질의와 문서의 임베딩 벡터를 생성하고, 코사인 유사도(Cosine Similarity)를 통해 의미적 관련성을 평가하였다.

키워드 검색

전통적으로 많이 사용되는 BM25(Best Matching 25) 알고리즘을 사용하여 질의에 포함된 특정 키워드가 문서 내에 얼마나 빈번하게 등장하는지를 평가하였다. 이는 전문 용어나 정확한 수치 검색에 강점을 가진다.

위와 같은 두 검색 알고리즘이 산출하는 유사도 점수의 스케일이 일치하지 않으므로, 단순 합산 시 특정 알고리즘 편향이 발생할 수 있다. 이를 방지하기 위해 본 연구에서는 각 검색 결과의 점수에 대하여 최소-최대 정규화(Min-Max Normalization)를 적용하여 스케일을 일치시키고, 정규화된 점수에 가중치 파라미터 α 를 적용하여 최종 점수(S_{final})를 산출하였다.

$$S'_{\text{vec}} = \frac{S_{\text{vec}} - \min S_{\text{vec}}}{\max S_{\text{vec}} - \min S_{\text{vec}}}, \quad S'_{\text{key}} = \frac{S_{\text{key}} - \min S_{\text{key}}}{\max S_{\text{key}} - \min S_{\text{key}}}$$

$$S_{\text{final}} = \alpha \cdot S'_{\text{vec}} + (1 - \alpha) \cdot S'_{\text{key}}$$

여기서 S'_{vec} 와 S'_{key} 는 각각 정규화된 의미 기반 검색 점수와 키워드 검색 점수를 의미한다. 본 연구에서는 의미 기반 검색의 중요도를 다소 높게 반영하여 $\alpha = 0.6$ 으로 설정하였다.

4. MatKV 기법 적용에 따른 성능 점검

제한된 하드웨어 자원을 사용하는 오프라인 환경에서 RAG시스템의 응답 속도와 자원 효율성을 극대화하기 위해 MatKV(Materialized Key-Values) 기법을 적용하고 성능 향상 정도를 점검하였다.

질의가 입력되면 RAG시스템은 질의별로 검색된 문서를 LLM에 입력하게 되고 LLM은 이 문서들을 이해하기 위해 ‘사전 연산 단계(prefill)’를 거치게 되는데, 이 때 텍스트를 KV cache 형태로 변환하는 과정에서 상당한 GPU자원과 시간을 소모하게 된다. MatKV는 LLM 추론 과정 중 가장 높은 연산 비용과 시간이 소요되는 사전 연산 단계의 부하를 줄이는 기법이다. 문서를 vectorDB로 저장할 때 문서들의 KV cache를 미리 계산하여 저렴하고 빠른 SSD 저장장치에 저장해 두었다가 필요시 고비용의 GPU자원을 소모하여 KV cache를 계산하는 대신 SSD에 미리 저장된 KV cache를 스트리밍 형태로 가져와서 분석하는 방법이다. 이는 사전 연산 단계에서 소요되는 추론 시간과 전력 소모를 줄인다[8].

본 연구에서는 오프라인 RAG시스템 특성상 로컬PC의 저장장치¹ 및 RAM 용량² 등 시스템 자원의 한계로 인해, MatKV 기법에 한하여 보다 경량화된 LLM

¹본 연구에 사용된 로컬PC는 일반적인 기업에서 주로 사용되는 보편적인 성능의 PC로 16GB의 RAM과 512GB의 저장장치 용량을 가지고 있는데, 일반적으로 1k 토큰이 Llama3.1:8B 기준으로 250MB의 저장용량을 필요로 하여, 본 연구에 사용된 1,200여개의 PDF를 모두 캐시로 저장할 경우 약 1TB 이상의 저장용량이 필요하게 되어 저장용량이 부족한 문제가 발생

²KV cache를 저장장치에 저장하고 LLM연산과정에서 사용하기 위해서는 LLM 모델을 직접 메모리에 올려야 하는데 Llama3.1:8B 모델을 사용하기 위해서는 약 16GB의 메모리가 필요하여 추가 연산이 메모리부족으로 종료되는 문제가 발생

모델인 Llama3.2-1B 모델과 100개의 샘플 PDF문서, 100개 문서에서 생성된 169개의 QAsset을 활용하여 실험을 진행하고 그 결과값을 참고용으로 제시하였다.

제 4 절 결과 분석 및 시사점 도출

실험 결과를 종합하여 ① 도메인 특화 문서검색의 정확도 향상 가능성, ② 보안·비용 제약 환경에서의 실용적 활용성, ③ RAG 및 임베딩 최적화 기법의 실무적 기여를 분석한다. 이를 통해 금융권역 뿐 아니라 다양한 업권에서 적용 가능한 특화형 RAG 문서검색 시스템의 설계 원리와 적용 가능성을 도출하였다.

제 4 장 연구 결과 및 분석

제 1 절 평가 지표 설정

본 연구에서는 RAG검색시스템의 성능을 다각도로 분석하기 위해 해당 질의에 대한 정보가 포함되어 있는 정답 문서의 검색 성능과 질의에 대한 답변의 정확성을 각각 측정하였다.

1. 정답 문서 검색 성능 평가지표

본 연구에서는 RAG검색시스템이 모델별로 사용자의 질의(Query)에 부합하는 정답 문서(Ground Truth Document)를 얼마나 정확하게 추출해냈는지를 평가하기 위해 Hit@K와 MRR(Mean Reciprocal Rank)을 사용하였다.

- **Hit@K** 질의 q 에 대하여 RAG시스템이 제시한 상위 K 개의 문서 목록 내에 실제 정답 문서가 포함되어 있는지를 측정하는 지표이다. 본 연구에서는 $K = 1, 3, 5, 10$ 으로 설정하여, 문서 목록 상위 1순위 검색의 정확도 뿐만 아니라 다양한 범위에서 검색 정확도를 확인하고 이를 성능으로 평가하였다.

$$Hit@K = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \mathbb{1}(r_i \leq K)$$

Q : 질의 집합, r_i : i 번째 질의에 대한 정답 문서의 순위

- **MRR(Mean Reciprocal Rank)** MRR은 정답 문서가 검색 결과의 상위에 위치할수록 높은 점수를 부여하는 지표이다. 이 지표를 통해 RAG시스템이 정답을 얼마나 ‘가장 관련성 높은 문서’로 인식하고 있는지를 평가한다. 이는 RAG시스템 내부적으로 K 개의 문서를 LLM에 입력할 때, 상위에

위치한 문서가 답변 생성에 더 큰 영향을 미칠 수 있다는 점을 고려한 것이다.

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{r_i}$$

2. 질의에 대한 답변의 정확성 평가지표

본 연구에서는 RAG검색시스템이 산출한 답변이 사용자의 질의(Query)에 대하여 사전에 마련한 실제 정답(gold answer)과 의미적으로 일치하는지를 평가하기 위해, 정량적 매칭과 의미론적 평가를 결합한 **pass rate**를 사용하였다.

- **정답률(Pass Rate)** 본 연구에서는 단순한 문자열 완전 일치(Exact Match)가 가지는 한계를 극복하기 위해, 다음과 같은 다단계 검증 로직을 구성하여 답변의 정답 여부(Pass)를 판정하였다.

1. **완전 일치(Exact Match):** 예측 답변과 정답이 문자열 수준에서 동일한 경우.
2. **퍼지 매칭 및 수치 검증(Fuzzy & Numeric Match):** 날짜·금액 등 핵심 수치 정보가 포함되어 있고, 문자열 유사도(Token Set Ratio)가 임계값(threshold, 86점) 이상인 경우.
3. **LLM 평가(LLM-as-a-Judge):** 위의 조건에는 부합하지 않으나 의미적으로 동일한 답변으로 판단되는 경우, 별도의 평가용 LLM(Evaluator)을 사용하여 최종적으로 일치 여부를 판정. 본 연구에서는 openAI의 ‘gpt-4o-mini’ LLM을 사용하였다.

3. 통합 평가지표

RAG 시스템의 가장 큰 위험 요소인 ‘환각(Hallucination)’과 ‘사전 지식에 의한 답변(Parametric Knowledge)’을 배제하고, 시스템이 실제로 검색된 문서를 근거

로 올바르게 답변했는지를 검증하기 위해 Hit@K와 pass 여부를 결합한 통합 성능 지표를 설정하였다.

- **Joint Score(Hit@K & Pass)** 이 지표는 상위 K 개 내에 정답 문서가 검색되었고(Hit@K), 동시에 생성된 답변도 정답(Pass)인 경우만을 성공으로 간주한다. 문서 검색에는 실패했으나 답변을 맞힌 경우를 LLM의 배경지식에 의존한 경우로 보아 이를 배제함으로써 RAG시스템 본연의 목적인 ‘근거 기반 생성’ 성능을 점검할 수 있는 지표로, 이를 통해 답변 생성과 문서 검색의 통합 성능을 측정하였다.

4. 질의별 평균 소요시간

본 연구에서는 시스템의 정확성뿐만 아니라 실제 운용시 답변 지연시간 등의 실용성을 검증하기 위해, 질의 처리 속도를 나타내는 질의별 평균 소요시간을 측정하였다.

- **질의별 평균 소요시간(Average Latency)** RAG시스템이 질의를 입력받은 시점부터 시스템이 최종 답변을 생성하여 출력하기까지 소요된 전체 시간을 의미하며, 본 연구에서는 QA set에 대한 질의별 소요시간의 평균값(평균 소요시간)을 측정하였다. 평균 소요시간은 크게 문서 검색 시간($t_{retrieval}$)과 답변 생성 시간($t_{generation}$)의 합으로 계산될 수 있다.

$$Average Latency = \frac{1}{|Q|} \sum_{i=1}^{|Q|} (t_{retrieval,i} + t_{generation,i})$$

RAG시스템은 일반적인 LLM과 달리 ‘검색’ 과정이 추가되므로, 검색 모델의 크기, 하이브리드 검색(Hybrid Search), matKV 등의 기법 적용 여부에 따라 응답 속도가 크게 달라질 수 있다. 따라서 이 지표는 시스템의 정확도

향상을 위해 도입한 방법론들이 문서 검색에 사용한 시스템 자원 등에 따른 소요시간과, 답변 응답 지연시간에 따른 사용자 경험 측면에서 어느 정도의 트레이드-오프(Trade-off)를 가지는지 분석하는 데 활용될 수 있다.

제 2 절 청크 크기에 따른 RAG시스템의 성능 변화

청크(Chunk)의 크기가 RAG시스템의 문서 검색 및 답변 성능에 미치는 영향을 분석하였다. 청크 크기별 성능 측정은 openAI의 ‘gpt-4o-mini’ 모델과 ‘text-embedding-3-small’ 임베딩 모델을 기반으로 하였다. 기업 보고서의 특성을 활용, 문서 내 줄바꿈 구조를 반영하여 문장의 의미를 유지하면서 청크 크기를 300자에서 1000자까지 100자 단위로 단계적으로 증가시키며 비교 실험을 진행하였다. 각 설정에 따른 성능 평가는 검색 정확도(Hit@K, MRR), 답변 정답률(Pass Rate), 그리고 통합 지표(Joint Metrics)를 종합적으로 분석하여 이루어졌다.

1. 청크 크기에 따른 문서 검색 성능 비교

청크 크기가 작을수록(300자) 전반적인 검색 성능이 우수한 경향을 보였다.

표 4.1: Chunk Size별 문서 검색 성능 비교

Chunk Size	Hit@1	Hit@3	Hit@5	Hit@10	MRR
300	0.397	0.550	0.602	0.646	0.487
400	0.393	0.537	0.593	0.643	0.478
500	0.373	0.543	0.597	0.640	0.468
600	0.390	0.533	0.590	0.640	0.477
700	0.363	0.527	0.580	0.643	0.464
800	0.370	0.530	0.590	0.613	0.459
900	0.383	0.523	0.567	0.613	0.468
1000	0.397	0.517	0.583	0.633	0.476

- **Hit@K, MRR** 가장 작은 단위인 300자 청크에서 MRR 0.487로 가장 높은 수치를 기록하였으며, Hit@1을 포함한 모든 Hit@K ($K = 1, 3, 5, 10$)

역시 300자 청크에서 제일 우수한 성능을 보였다. 이는 청크 크기가 작을수록 질의(Query)와 직접적으로 연관된 핵심 문장이 밀집되어 있어, 벡터 유사도 계산시 노이즈가 적게 반영되기 때문인 것으로 해석된다.

- **성능 하락 구간 존재** 청크 크기가 400자에서 900자로 증가함에 따라 MRR 및 상위권 검색 정확도(Hit@3, Hit@5)는 대체로 소폭 하락하는 경향을 보였다. 특히 700~900자 구간에서 Hit@1 지표가 0.363~0.383 수준으로 낮아지는 현상이 관찰되었다.
- **대형 청크에서의 성능 향상** 1,000자 청크에서 Hit@10이 300자 청크와 동일한 0.397을 기록하였는데, 이는 긴 문맥이 필요한 특정 질문 유형에서는 대형 청크가 정확한 문서를 찾아내는 데에 유리하게 작용한 결과로 추측된다.

2. 청크 크기에 따른 답변의 정확도

검색된 문서를 바탕으로 LLM이 답변을 생성하는 성능(Pass Rate)과, 올바른 문서를 검색하고 동시에 정답을 맞힌 비율(Joint Score)을 분석하였다.

표 4.2: Chunk Size별 답변 생성 및 통합 성능 비교

Chunk Size	Pass Rate	Joint Hit@1	Joint Hit@3	Joint Hit@5	Joint Hit@10
300	0.593	0.354	0.399	0.407	0.414
400	0.600	0.360	0.393	0.397	0.403
500	0.570	0.320	0.360	0.370	0.373
600	0.590	0.343	0.383	0.400	0.413
700	0.583	0.320	0.353	0.373	0.390
800	0.597	0.337	0.380	0.407	0.407
900	0.567	0.343	0.370	0.383	0.393
1000	0.597	0.357	0.380	0.407	0.417

- **Pass Rate(정답률)** 검색 성능이 가장 좋았던 300자 청크(0.593) 대비, 400자 청크에서 0.600으로 가장 높은 답변 정확도를 기록하였다. 또한, 800

자 및 1000자 청크에서도 0.597의 높은 정확도를 보여, 단순히 검색 점수 (MRR)가 높다고 해서 반드시 답변 정확도가 비례하여 상승하지 않음을 확인하였다. 이는 LLM이 답변을 생성할 때, 너무 짧은 문맥보다는 어느 정도 충분한 주변 정보를 포함한 문맥(400자 이상)을 제공받았을 때 더 정확한 추론이 가능함을 의미한다.

- **통합 평가지표** 검색과 생성이 모두 성공한 Joint Hit@1 지표는 400자 청크에서 0.360으로 가장 높았으나, Joint Hit@3 및 Joint Hit@5 지표는 300자 청크에서 제일 높은 수치를 보였다.

3. 결론

본 실험을 통해 금융 도메인 RAG 시스템에서 최적의 청크 크기를 도출한 결과, 검색 효율성 측면에서는 300자 청크가 가장 높은 MRR(0.487)과 Hit@K 수치를 보여 정답 문서의 순위를 높이는 데 가장 유리하였으나, 답변 품질 측면에서는 400자 청크가 가장 높은 답변 정답률(60.0%)과 통합 성능(Joint Hit@1 36.0%)을 달성하여 검색 정확도와 생성 문맥의 풍부함 사이에서 최적의 균형점인 것으로 판단된다. 그러나 Joint Hit@3 및 Joint Hit@5 지표에서는 300자 청크가 가장 높은 통합 성능을 보이는 점, 본 연구는 RAG시스템을 통한 검색 성능을 우선적으로 고려하고 있는 점을 감안하여 300자 청크 크기를 기본적인 분석 단위로 정하였다.

제 3 절 온라인 LLM 성능 점검

온라인에서 범용적으로 사용되는 OpenAI 임베딩 모델과, 검색 등 RAG시스템에 특화된 VoyageAI 임베딩 모델을 사용하여 LLM을 활용한 RAG시스템의 성능 상한을 살펴보고 이를 오프라인 LLM을 활용한 RAG시스템의 성능 수준을 점검하는 기준으로 정하였다.

점검 결과, VoyageAI 임베딩 모델과 openAI의 gpt-4o-mini를 결합한 RAG

표 4.3: OpenAI와 VoyageAI 임베딩 모델 성능 측정

Model	Hit@1	Hit@10	MRR	Pass Rate	Joint Hit@1	Joint Hit@10	Avg Time (s)
OpenAI	0.397	0.646	0.487	0.593	0.354	0.414	2.128
VoyageAI	0.554	0.696	0.611	0.772	0.504	0.552	1.930

시스템은 Hit@1 0.554, Hit@20 0.703, MRR 0.611, Pass Rate 0.772라는 높은 성능을 기록하면서도 질의별 평균 소요시간이 1.930초로 openAI 모델이 기록한 2.128초 대비 빠르게 처리되는 모습을 보였다. 이에 본 연구에서는 VoyageAI가 기록한 수치를 해당 QA 데이터셋에서 기대할 수 있는 실질적 최고 성능으로 간주하였다.

제 4 절 오프라인 LLM 성능 점검

오프라인 로컬 LLM을 활용한 RAG시스템의 성능 고도화를 위해 Ollama 3.1:8B LLM 모델과 BGE-M3 임베딩 모델을 기반으로 단계적 실험을 수행하였다. 실험은 ①기본 모델(Baseline), ②금융 특화 미세조정(Fine-tuned), ③하이브리드 검색(Hybrid Search), ④MatKV 기법 적용의 4단계로 진행되었으며, 각 단계별로 문서 검색 정확도(Hit@K, MRR)와 답변 생성 품질(Pass Rate, Joint Hit)을 종합적으로 평가하였다.

표 4.4: 오프라인 LLM을 활용한 RAG 시스템 성능 비교

Stage	Hit@1	Hit@10	MRR	Pass Rate	Joint Hit@1	Joint Hit@10	Avg Time (s)
Baseline	0.527	0.663	0.579	0.693	0.403	0.443	6.457
Fine-tuned	0.528	0.666	0.582	0.697	0.407	0.447	7.511
Hybrid	0.535	0.678	0.590	0.701	0.417	0.440	8.061

기본 모델의 성능 실험 결과, Hit@1 0.527, MRR 0.579를 기록하며 나쁘지 않는 성능을 보였다. 이어서 수행된 미세조정 단계에서는 검색 성능 지표(Hit@K,

MRR)가 기본 모델 대비 소폭 증가한 수치(Hit@1: +0.001, MRR: +0.003)를 기록하였다. 최종 답변 정답률(Pass Rate)은 0.697로, 그리고 검색과 정답 생성이 모두 성공한 Joint Hit@1 역시 0.407로 기본 모델 대비 소폭 상승(Pass rate: +0.004, Joint Hit@1: +0.004)하였다. 이는 본 연구에 적용된 미세조정이 기존 모델의 일반적인 검색 능력을 저해하지 않으면서, LLM이 정답을 생성하는 데 필요한 문맥적 적합성을 미세하게 개선하는 데 기여했음을 의미한다. 즉, 벡터 공간 내에서 질문과 문서 간의 정렬이 강화되어 생성 모델의 판단에 긍정적인 영향을 미친 것으로 해석된다.

미세조정 모델에 키워드 매칭(BM25)을 결합한 하이브리드 검색 단계에서 가장 뚜렷한 성능 향상이 관찰되었다. Hit@1은 0.535로, MRR은 0.590으로 상승하여 기본 모델 대비 약 2.3%의 성능 개선(Hit@1 기준)을 달성하였다. 이는 벡터를 활용하는 의미 기반 검색이 놓칠 수 있는 정확한 수치값이나 고유명사(금융 전문 용어 등)를 키워드 검색이 보완해 줌으로써, 상호보완적인 시너지 효과를 낸 결과라고 볼 수 있다.

또한, RAG 시스템의 신뢰성을 나타내는 핵심 지표인 통합 지표 중에서도 1순위 매칭이 이루어졌는지를 살펴볼 수 있는 Joint Hit@1 지표에서 0.417로 최고점을 기록하였다. 이는 전체 질의의 약 41.7%에 대해 시스템이 정답 문서를 최상위에 노출시키고, 이를 근거로 올바른 답변을 생성했음을 의미한다. 전체 정답률 역시 하이브리드 검색을 활용한 실험에서 0.701을 기록하여 제일 준수한 성능을 보이고 있으며, Joint Hit 비율 역시 Joint Hit@1에서 0.417을 보임으로써 제일 좋은 수치를 기록하였다. 이는 하이브리드 검색을 활용한 RAG시스템이 환각이나 배경지식에 의존하기보다 검색된 증거에 기반하여 답변하는 능력이 강화되었음을 방증한다.

한편, 질의 처리 효율성을 나타내는 평균 소요시간(Average Time) 측면에서는 단계별 고도화에 따라 연산 비용이 증가하는 경향이 관찰되었다. 기본 모델은 질

의당 평균 6.457초를 기록하였으나, 미세조정 모델은 7.511초, 하이브리드 검색은 8.061초로 소요 시간이 점진적으로 증가하였다. 이는 검색 알고리즘의 복잡도가 증가하고, 특히 하이브리드 검색 단계에서 벡터 검색과 키워드 검색 결과를 결합하는 추가 연산이 수행됨에 따른 자연스러운 결과로 해석된다.

제 5 절 종합 성능 비교 분석

1. 온라인 vs 오프라인 LLM 성능 비교

본 연구에서 제안하는 ‘오프라인 하이브리드 RAG 시스템’의 실질적인 효용성을 검증하기 위하여, 앞서 제 3 절에서 성능 상한선으로 설정하였던 ‘VoyageAI 기반 온라인 RAG 시스템’과 성능을 비교·분석하였다. 두 시스템 간의 주요 성능 지표 비교는 표 4.5과 같다.

표 4.5: 온라인(VoyageAI)과 오프라인 제안 모델(Hybrid) 성능 비교

Model	Hit@1	Hit@10	MRR	Pass Rate	Joint Hit@1	Joint Hit@10	Avg Time (s)
VoyageAI	0.554	0.696	0.611	0.772	0.504	0.552	1.930
Hybrid	0.535	0.678	0.590	0.701	0.417	0.440	8.061
<i>Gap(Δ)</i>	<i>-0.019</i>	<i>-0.018</i>	<i>-0.021</i>	<i>-0.071</i>	<i>-0.087</i>	<i>-0.112</i>	<i>+6.131</i>

- 1. 검색 정확도** 문서 검색 성능을 나타내는 지표인 Hit@1과 MRR에서 오프라인 하이브리드 모델은 RAG에 특화된 상용 모델인 VoyageAI 대비 각각 1.9%p, 2.1%p의 격차를 보였다. 특히 Hit@1 기준 96.6% 수준(0.535/0.554)의 성능을 달성함으로써, 오프라인 모델을 사용하는 환경에서도 도메인 특화 미세조정과 하이브리드 검색 기법을 통해 대규모 상용 모델에 버금가는 검색 정확도를 확보할 수 있음을 실증하였다.

2. **생성 모델에 따른 답변 품질 차이** Hit@1 기준 근소한 차이를 보이는 검색 정확도에도 불구하고, 최종 답변 정답률에서는 약 7.1%p의 성능 차이가 발생하였다. 이는 RAG시스템 내에서 답변을 생성하는 LLM의 성능 차이로 인한 것으로, VoyageAI를 활용한 RAG시스템은 고도화된 추론 능력을 갖춘 gpt-4o-mini LLM을 사용한 반면, 오프라인 RAG시스템은 80억(8B) 파라미터 규모의 경량화된 Llama3.1:8B 로컬 모델을 사용했기 때문인 것으로 판단된다. 그러나 결과상으로는 오프라인 모델 또한 70% 이상의 정답률을 기록하며 실무에서 적용이 가능한 수준의 성능을 보여주었다.

3. **효율성과 보안성의 트레이드-오프** 평균 소요시간 측면에서 오프라인 모델(8.061초)은 온라인 모델(1.930초) 대비 약 4배 느린 응답 속도를 보였다. 이는 온라인 모델이 고성능 GPU 기반의 온라인 API 서비스를 활용한 반면 오프라인 모델의 경우 로컬 단일 GPU 환경에서 실행되었기 때문에 발생한 문제로, 직접적인 물리적 성능 차이가 그 원인으로 지목된다. 그러나 외부망으로 데이터를 전송하지 않아도 되는 데이터 보안성, API 비용이 발생하지 않는 경제성 측면을 고려할 때, 약 8초 내외의 응답 시간은 기업 내부망 환경에서 충분히 사용 가능한 수준이라고 볼 수 있다.

2. 검색 성능 저해 요인 분석: 데이터 특성을 중심으로

앞선 실험을 통해 오프라인 하이브리드 RAG시스템이 온라인 모델에 근접하는 성능을 보였으나, 절대적인 검색 정확도(Hit@1) 측면에서는 90% 이상의 정확도를 보이지 못하는 한계를 확인할 수 있었다. 본 연구에서는 이러한 성능 한계의 원인을 모델 아키텍처의 문제보다는 실험에 사용된 금융 도메인 데이터셋의 특성에서 기인한 것으로 분석하였으며, 주요 요인은 다음과 같다.

1. **다중 출처 데이터의 이질성** 본 연구에 사용된 기업 문서 자료는 단일 기업의 문서가 아닌, 금융위원회, 금융감독원, 한국은행 등 서로 다른 조직 문화를

가진 3개 기관의 보도자료와 보고서로 구성되어 있다. 이들 기관은 동일한 금융 현상을 다루더라도 문서의 구조, 문체, 그리고 전문 용어의 선택에서 미세한 차이를 보인다. 이러한 표현의 다양성은 의미적으로는 동일하나 벡터 공간상에서는 서로 다른 위치에 있게 되므로, 검색 모델이 질의와 정확히 일치하는 문서를 식별하는 데 혼란을 초래하는 요인으로 작용하였다.

2. **협력 기관 간 서술의 불일치** 위 3개 기관은 금융 정책 수립 및 집행 과정에서 긴밀히 협력하는 경우가 많으나, 대외 커뮤니케이션(보도자료 등) 단계에서는 각 기관의 관점에 따라 동일 사안에 대하여도 강조점을 달리하는 경향이 있다. 이는 하나의 사건에 대해 서로 다른 뉘앙스를 가진 문서들이 공존하게 만듦으로써, 검색 시 유사 정답 문서들이 상위권에 포함되는 노이즈로 작용하였다.

3. **정보의 시계열적 변화 및 중복성** 보도자료 데이터의 특성상 하나의 정책이나 행사는 ‘계획 수립 → 진행 → 결과 발표’의 생애주기를 거치며 여러 건의 문서로 생성된다. 이 과정에서 초기 계획 단계의 수치와 최종 결과 단계의 수치가 달라지는 경우가 발생할 수 있다(예: 제19회 금융공모전 사례, 개최 보도자료상의 예상 시상 인원은 175명이었으나 시상식 보도자료에서의 실제 시상 인원은 총 161명).

이러한 경우, 질의에 대한 답변이 특정 시점의 문서에만 존재할 수 있다. 이는 정답 문서의 유일성을 모호하게 만들게 되는데, 이처럼 의미적으로는 유사하나 시점이 차이로 인해 오답이 되는 문서는 검색 모델의 성능을 저하시키는 하드 네거티브(Hard Negative) 문제를 심화시키는 주요 원인이다.

또한, 특정 지표들은 시간 경과에 따라 산출 방식이 변경될 수 있으며, 보도자료 등 발표 이후 추가적인 데이터 수집에 의한 보정으로 인해 수치가 갱신될 수 있다. 보도자료에서는 이러한 변경 사항을 ‘잠정치’와 ‘확정치’ 등

으로 구분하여 명시하고 있으나, LLM이 문서 내의 미세한 문맥적 단서를 정교하게 파악하지 못할 경우, 과거의 잠정치를 정답으로 인용하는 등 수치 정보의 정확도가 저해되는 문제가 발생할 가능성이 있다.

결론적으로, RAG시스템의 성능을 추가적으로 향상시키기 위해서는 단순한 모델 미세조정을 넘어 문서의 발행 시점과 기관별 특성을 포함하고 있는 메타데이터를 활용한 메타데이터 필터링 기법, 문서의 시계열 정보를 반영한 시계열 정보 기반 랭킹 기법의 도입이 필요하다.

3. MatKV 기법 적용에 따른 성능 점검

MatKV기법을 통해 검색 소요시간 등 성능 향상 정도를 측정한 결과는 다음과 같다. 이 실험에서는 제 3 장 제 3 절 4.에서 언급하였듯이 시스템 자원의 한계로 인해 보다 경량화된 LLM모델인 Llama3.2-1B 모델과 100개의 샘플 PDF문서, 100개 문서에서 생성된 169개의 QASET을 활용하여 MatKV 적용 실험을 진행하였다.

표 4.6: LLM 모델별, MatKV 기법 적용별 성능 비교

LLM Model	MatKV	hit@1	hit@3	hit@5	hit@10	MRR	pass rate	Avg Time (s)
Llama3.1:8B	X	0.828	0.852	0.858	0.858	0.841	0.817	9.892
Llama3.2-1B	X	0.828	0.852	0.858	0.858	0.841	0.444	7.299
Llama3.2-1B	O	0.828	0.852	0.858	0.858	0.841	0.101	2.536

문서 검색 측면에서는 matKV 기법을 적용한 모델(Llama3.2-1B)의 결과값이 Llama3.1:8B 모델을 사용한 결과값과 동일하며, 이는 matKV기법에 따른 추가적인 성능 저하 없이 검색 정확도를 유지할 수 있음을 보여준다.

답변 생성의 정확도 측면에서는 matKV의 결과가 0.101로 Llama3.1:8B모델의 0.817과 Llama3.2-1B에 matKV를 적용하지 않은 모델의 0.444보다 낮은 수치를 보이고 있다. 이는 로컬PC 자원의 한계로 인해 LLM 모델을 본 연구에 사용하던 Llama3.1:8B모델이 아닌 더욱 경량화된 Llama3.2-1B 모델을 사용함에 따른

추론 능력의 한계가 반영된 결과로 해석된다. 주목할 점은 동일한 Llama-3.2-1B 모델 내에서도 MatKV 적용 여부에 따라 Pass Rate가 0.444에서 0.101로 추가 하락했다는 점이다. 이는 MatKV의 압축된 KV 캐시 표현 방식이 검색 속도는 높여 주지만, LLM이 문맥을 정교하게 이해하고 답변을 생성하는 과정에서는 정보 손실을 유발할 수 있음을 시사한다.

한편, 질의당 평균 소요시간은 matKV 실험값이 2.536초로 Llama3.1:8B 모델의 9.892초와 matKV를 적용하지 않은 Llama3.2-1B 모델의 7.299초 대비 상당히 빠른 결과를 보였다. 이는 온라인 LLM모델인 voyageAI를 활용한 실험값인 1.930초와 비교하여도 크게 차이를 느끼지 못하는 수준으로, matKV 적용을 통해 질의에 대한 실시간 답변이 가능한 수준의 응답 속도를 확보했음을 의미한다.

본 실험에서 문서 검색 정확도가 Hit@1 기준 82.8%라는 높은 수치를 기록한 점은 실험 데이터셋의 특성에 기인한다. 실험에 활용된 문서는 총 100건의 금융감독원 보도자료로, 데이터의 규모가 작아 2.에서 분석한 대규모 데이터셋의 성능 저해 요인으로부터 비교적 자유롭기 때문이다. 또한, 문서 작성 스타일이 정형화된 문서 데이터를 활용할 경우, 경량화 모델에서도 높은 검색 정확도를 달성할 수 있음을 확인하였다.

종합적으로, MatKV 기법은 저장 공간이 충분히 확보된 환경에서 문서 검색의 정확도를 손실 없이 유지하면서 시스템의 응답 속도를 획기적으로 개선할 수 있는 방안을 확인하였다. 비록 생성 모델의 경량화 등으로 인해 답변 생성의 품질은 저하되었으나, 신속하고도 정확한 문서 검색이 우선시되는 RAG시스템 구축에 있어 MatKV는 유효한 선택지가 될 수 있을 것이다.

제 5 장 결 론

제 1 절 고 찰

종합적으로 볼 때, 본 연구에서 제안한 오프라인 RAG시스템은 온라인 고성능 모델을 활용한 RAG시스템 대비 검색 정확도 면에서 대등한 수준을 구현할 수 있음을 보였다. 비록 답변 성능과 응답 속도에서는 일부 격차가 존재하지만, 이는 보안이 필수적인 기업 내부망 환경에서 API등 외부 의존성 없이 고성능의 금융 정보 검색 시스템을 독자적으로 구축할 수 있다는 점에서 중요한 실무적 의의가 있다. 향후 로컬 LLM의 추론 성능 향상이나 경량화 기술 발전에 따라 이러한 성능 격차는 더욱 좁혀질 것으로 기대한다.

제 2 절 향후 과제

본 연구에서는 제한된 공개 데이터(금융용어사전)를 활용하여 로컬 RAG시스템의 성능 개선 가능성을 확인하였으나, 금융 도메인의 복잡성과 특수성을 완벽하게 반영하기 위해서는 보다 방대하고 정교한 도메인 특화 데이터의 확보가 필수적이라고 할 수 있다.

이와 관련하여 현재 금융위원회와 금융결제원에서는 금융권역의 원활한 AI 활용 지원을 목표로 ‘금융말뭉치 시범사업’을 진행하고 있다. 해당 사업은 사전학습용, 파인튜닝용, 검색증강생성(RAG)용 등으로 구성된 금융말뭉치를 제공하는 사업으로, 사업에서 제공하고 있는 특화된 금융말뭉치를 활용하여 임베딩 모델을 추가적으로 미세조정하는 경우 추가적으로 RAG시스템 성능을 향상시킬 수 있을 것으로 보인다.

향후 해당 금융말뭉치 데이터를 확보하여 본 시스템에 적용하고 성능 향상 여

부를 실증적으로 검증하는 추가 연구를 통해 데이터의 양적·질적 확장이 오프라인 로컬 RAG시스템의 성능에 얼마나 영향을 줄 수 있을지 살펴볼 수 있을 것이다.

금융말뭉치 시범사업 실시

참고문헌

- [1] R. Akkiraju, A. Xu, D. Bora, T. Yu, L. An, V. Seth, A. Shukla, P. Gundecha, H. Mehta, A. Jha, P. Raj, A. Balasubramanian, M. Maram, G. Muthusamy, S. R. Annepally, S. Knowles, M. Du, N. Burnett, S. Javiya, A. Marannan, M. Kumari, S. Jha, E. Dereszewski, A. Chakraborty, S. Ranjan, A. Terfai, A. Surya, T. Mercer, V. K. Thanigachalam, T. Bar, S. Krishnan, J. Jaksic, N. Algarici, J. Liberman, J. Conway, S. Nayyar, and J. Boitano, “Facts about building retrieval augmented generation-based chatbots,” *arXiv preprint arXiv:2407.07858*, 2024.
- [2] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, M. Wang, and H. Wang, “Retrieval-augmented generation for large language models: A survey,” *arXiv preprint arXiv:2312.10997*, 2023.
- [3] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, “M3-embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation,” *arXiv preprint arXiv:2402.03216*, 2024.
- [4] Voyage AI, “voyage-3.5 and voyage-3.5-lite: improved quality for a new retrieval frontier.” <https://blog.voyageai.com/2025/05/20/voyage-3-5/>, May 2025. Online; accessed 2025-12-12.
- [5] T. Bosc and P. Vincent, “Auto-encoding dictionary definitions into consistent word embeddings,” *Association for Computational Linguistics*, pp. 1522–1532, 2018.

- [6] KuKu: Huggingface blog, “Mitigating false negatives in retriever training.” <https://huggingface.co/blog/dragonkue/mitigating-false-negatives-in-retriever-training>, May 2025. Online; accessed 2025-12-12.
- [7] X. Wang, Z. Wang, X. Gao, F. Zhang, Y. Wu, Z. Xu, T. Shi, Z. Wang, S. Li, Q. Qian, R. Yin, C. Lv, X. Zheng, and X. Huang, “Searching for Best Practices in Retrieval-Augmented Generation,” *arXiv preprint arXiv:2407.01219*, 2024.
- [8] K. W. Shin, J. H. Park, M. Oh, Y. Jo, J. Do, and S. W. Lee, “MatKV: Trading Compute for Flash Storage in LLM Inference,” *ICDE(2026)*, 2025.

Abstract

Efficient Document Search using Retrieval-Augmented Generation

Kim, Yong Min

Graduate School of Data Science, Data Science Major

The Graduate School

Seoul National University

The recent rapid development of Generative AI is shifting the paradigm of knowledge management. However, due to security concerns and cost constraints, it is difficult to directly utilize external API-based online large-scale language models (LLMs) for unstructured documents such as internal corporate reports. Therefore, this study proposes a local PC-based financial domain-specific Retrieval-Augmented Generation (RAG) system that utilizes offline language models to address security and cost constraints while achieving practical search performance.

To simulate the environment used for corporate reports, this study collected 1,295 documents, including reports and press releases from the Financial Supervisory Service, Financial Services Commission, and Bank of Korea. These documents were used to build a finance-specific benchmark dataset. To optimize search performance, a dedicated chunking technique was designed that reflects the characteristic, recursion-like structure of corporate documents. To

generate an embedding model specialized for the financial sector, the BGE-M3 embedding model was fine-tuned using a financial glossary. Furthermore, a hybrid search strategy combining semantic search and keyword search(BM25 algorithm) was applied to improve document retrieval accuracy.

As a result, the offline hybrid RAG system achieved a Hit@1 score of 0.535, representing document retrieval performance, achieving approximately 96.6% of the performance of the VoyageAI-based system (0.554), the latest online commercial model. Furthermore, to overcome local PC resource constraints and improve response speed, the MatKV (Materialized Key-Values) technique was applied. This dramatically reduced the average query time from 9.892 seconds to 2.536 seconds while maintaining document retrieval accuracy, achieving real-time responsiveness comparable to the online voyage model's average time of 1.930 seconds.

The value of this study is grounded in its empirical validation that a high-performance financial document retrieval system, competitive with commercial solutions, can be autonomously developed using offline LLMs and advanced retrieval strategies, even within security-constrained corporate networks.

Keywords: Retrieval-Augmented Generation(RAG), Finance-specific, Offline LLM, Hybrid Search, MatKV, Fine-tuning

Student Number: 2024-26529